МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)

Институт №8 «Информационные технологии и прикладная математика»
Кафедра 806 «Вычислительная математика и программирование»

Лабораторная работа №1
по курсу «Программирование графических процессоров»

Освоение программного обеспечения для работы с технологией CUDA.

Примитивные операции над векторами.

Выполнил: М.А. Бронников
Группа: 8О-407Б
Преподаватели: К.Г. Крашенинников,
А.Ю. Морозов

Москва, 2020

Условие

Цель работы: Ознакомление и установка программного обеспечения для работы с программно-аппаратной архитектурой параллельных вычислений(CUDA). Реализация одной из примитивных операций над векторами.

Вариант 4. Поэлементное нахождение минимума векторов.

Программное и аппаратное обеспечение

Device: GeForce GT 545
Размер глобальной памяти: 3150381056
Размер константной памяти : 65536
Размер разделяемой памяти: 49152
Регистров на блок: 32768
Максимум потоков на блок: 1024
Количество мультипроцессоров : 3
OS: Linux Mint 20 Cinnamon
Редактор: VSCode

Метод решения

Для нахождения поэлементного минимума двух векторов достаточно вызвать количество нитей равное размеру массивов и записать в качестве результата минимум 2-ух соответствующих элементов массива по идентификатору в третий.

Описание программы

Для выполнения программы я реализовал собственный вектор в методе которого и вызывался kernel. Для того, чтобы выполнить поэлементную операцию минимума необходимо выделить 3 дополнительных блока памяти на device: в первых двух будут храниться 2 входных вектора, а в третий записываться результат. После аллокации я скопировал данные из векторов в выделенные массивы с помощью функции cudaMemcpy. После работы kernel я скопировал результат в выходной вектор с помощью аналогичной функции.

Для запуска kernel на device необходимо задать количество блоков и потоков в каждом из блоков. Для одномерного массива нам достаточно вызывать блоки и нити в одном измерении. Вызов kernel с заданным количеством нитей на блок:

```
elem_min<<<BLOCKS, MAXPTHS>>>(d_left, d_right, ans._size);
```

В самом kernel мы вычисляем общий индекс исполняемой нити который и будет индексом в массиве при условии idx < размер массива. Далее выполняем операцию нахождения минимума двух чисел из массивов с записью результа в третий:

```
template<typename T>
__global__ void elem_min(T* d_left, T* d_right, int size){
int idx = blockDim.x * blockIdx.x + threadIdx.x;
int step = blockDim.x * gridDim.x;

for(int i = idx; i < size; i += step){
T l_v = d_left[i];
T r_v = d_right[i];
d_left[i] = l_v < r_v ? l_v : r_v;
}
}
```

Результаты

Я провел небольшое исследование зависимости времени работы алгоритма от размера данных при разном количестве запущенных нитей GPU:

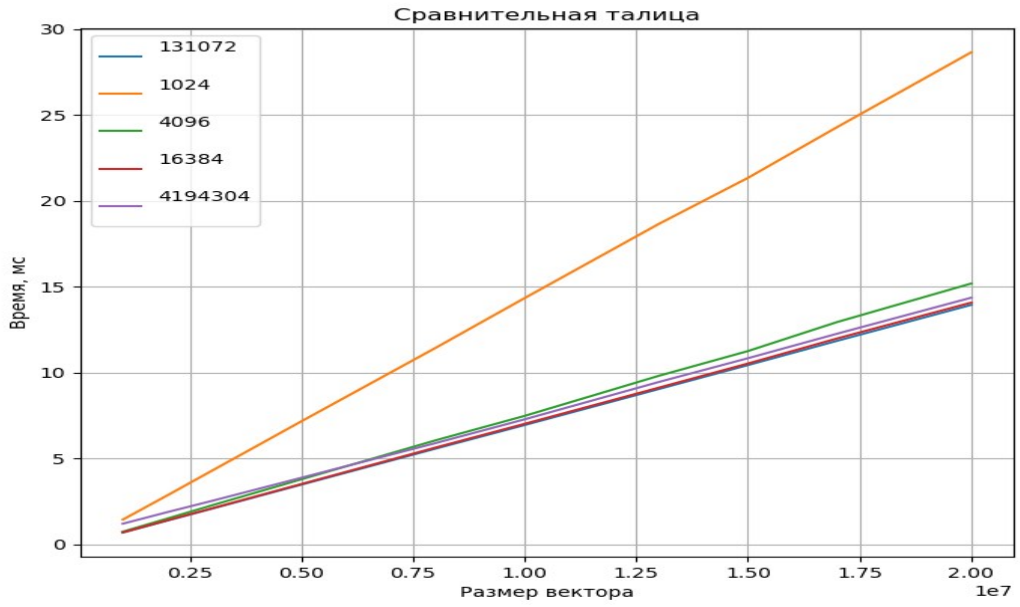

К моему удивлению, лучше всего показал запуск на количестве потоков, равном 1024(32 блока по 32 нити в каждом). Я объясняю это тем, что в таких блоках издержки на синхронизацию и переключение между нитями минимальны. Однако интересно посмотреть насколько велика разница между запуском на GPU и CPU:

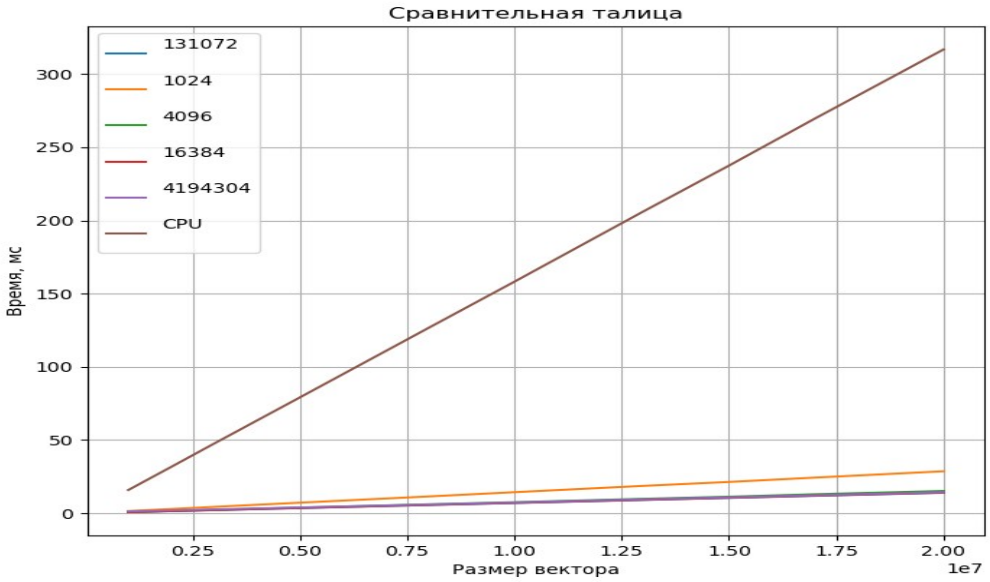

Разница GPU по сравнению с CPU очевидна при предельном размере вектора:

GPU (threads: 1024)
size: 33554432
time: 48.716ms

CPU
size: 33554432
time: 419.814ms

Выводы

Реализованный мной алгоритм является простым в программировании, поскольку это вводное задание в курс программирования графических процессоров. Но даже не смотря на это он может найти свое применение как небольшая часть крупных систем, в которых требуются быстрые операции над массивами и матрицами.

В ходе выполнения столкнулся с неудобством от того, что я не являюсь счастливым обладателем видеокарты Nvidia, что заставило искать обходные пути. Первая лабораторная работа была отлажена с помощью сервиса Google Collaboratory, который бесплатно предостовляет бесплатный доступ к видеокарте Nvidia Tesla 80K.

Однако несмотря на все трудности я выполнил работу, которая наглядно показала мне, насколько большое преимущество может дать использование графического процессора вместо центрального.