МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)

Институт №8 «Информационные технологии и прикладная математика»
Кафедра 806 «Вычислительная математика и программирование»

Лабораторная работа №2
по курсу «Программирование графических процессоров»

Обработка изображений на GPU. Фильтры.

Выполнил: М.А. Бронников
Группа: 8О-407Б
Преподаватели: К.Г. Крашенинников,
А.Ю. Морозов

Москва, 2020

Условие

Цель работы: Научиться использовать GPU для обработки изображений. Использование текстурной памяти.

Вариант 4. Метод Собеля.

Программное и аппаратное обеспечение

Device: GeForce GT 545
Размер глобальной памяти: 3150381056
Размер константной памяти : 65536
Размер разделяемой памяти: 49152
Регистров на блок: 32768
Максимум потоков на блок: 1024
Количество мультипроцессоров : 3
OS: Linux Mint 20 Cinnamon
Редактор: VSCode

Метод решения

Для каждого пикселя входного изображения следует выделить по отдельному потоку, каждый из которых будет обрабатывать окрестность этого потока. Поскольку при будет произведено много обращений к памяти, следует воспользоваться текстурной памятью, которая работает быстрее благодаря кэшированию. Результат обработки каждого пикселя будет записываться в выходной массив. Обработка производиться при помощи соответствующего ядра свертки.

Описание программы

Для выполнения программы я реализовал собственный класс изображения в методе которого и вызывался kernel. Чтобы влезть в ограничения по размеру с учетом размера текстурной памяти я считываю матрицу в транспонированном виде, если высота превышает ширину.
Для выполнения операции я создал текстурную ссылку в качестве глобального объекта, после чего выделил память для массива на девайсе, скопировал в нее массив-изображение и сделал бинд ссылки с массивом:

```
throw_on_cuda_error(
   cudaMalloc3DArray(&a_data, &cfDesc, {_widht, _height, 0})
);

throw_on_cuda_error(
   cudaMemcpy2DToArray(
```

```
            a_data, 0, 0, _data, _widht * sizeof(uint32_t),
            _widht * sizeof(uint32_t), _height, cudaMemcpyHostToDevice
        )
    );

    throw_on_cuda_error(
        cudaBindTextureToArray(g_text, a_data, cfDesc)
    );
```

Для аппаратной обработки граничных условий я использую Clamp аддресацию.

После расчета количества блоков по заданному количеству потоков на каждое из измерений я вызываю kernel:

```
    dim3 threads = dim3(MAX_X, MAX_Y);
    dim3 blocks = dim3(bloks_y, bloks_x);

    // run filter
    sobel<<<blocks, threads>>>(d_data, _height, _widht);
    throw_on_cuda_error(cudaGetLastError());
```

В самом kernel мы вычисляем общий индекс исполняемой нити который и будет индексом в массиве при условии idx < размер массива. Далее производим расчет оператора Собеля для соответствующего пикселя:

```
__global__ void sobel(uint32_t* d_data, uint32_t h, uint32_t w){
    int32_t idx = blockIdx.x * blockDim.x + threadIdx.x;
    int32_t idy = blockIdx.y * blockDim.y + threadIdx.y;

    if(idx >= w || idy >= h){
        return;
    }


    // ans pixel
    uint32_t ans = 0;

    // locate area in mem(32 bite)
    // compute grey scale for all pixels in area
    float w11 = GREY(tex2D(g_text, idx - 1, idy - 1));
    float w12 = GREY(tex2D(g_text, idx, idy - 1));
    float w13 = GREY(tex2D(g_text, idx + 1, idy - 1));
    float w21 = GREY(tex2D(g_text, idx - 1, idy));

    float w23 = GREY(tex2D(g_text, idx + 1, idy));
    float w31 = GREY(tex2D(g_text, idx - 1, idy + 1));
    float w32 = GREY(tex2D(g_text, idx, idy + 1));
    float w33 = GREY(tex2D(g_text, idx + 1, idy + 1));
```

```
    // compute Gx Gy
    float Gx = w13 + w23 + w23 + w33 - w11 - w21 - w21 - w31;
    float Gy = w31 + w32 + w32 + w33 - w11 - w12 - w12 - w13;

    // full gradient
    int32_t gradf = (int32_t)sqrt(Gx*Gx + Gy*Gy);
    // max(grad, 255)

    gradf = gradf > 255 ? 255 : gradf;
    // store values in variable for minimize work with global mem
    ans ^= (gradf << 16);
    ans ^= (gradf << 8);
    ans ^= (gradf);

    // locate in global mem
    d_data[idy*w + idx] = ans;
}
```

После вызова kernel я копирую данные в массив и освобождаю выделенную память.

Результаты

Для иллюстрации результатов работы алгоритма я выбрал 3 изображения:

После чего я применил конвертер в заданный в задании формат, который я взял из материалов от преподавателя. После чего я применил к ним свою программу, и конвертировал обратно в jpg. Полученные результаты:

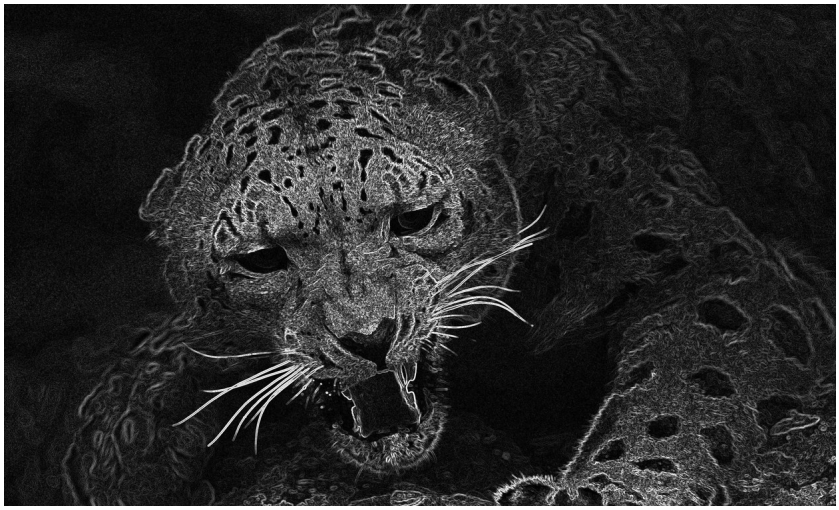

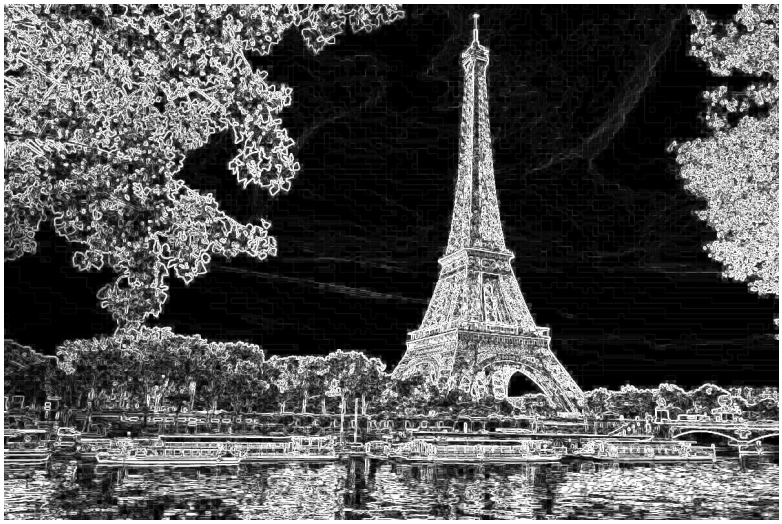

Я посмотрел как зависит время работы на этих изображениях от колличества потоков на один блок и получил следующий график:

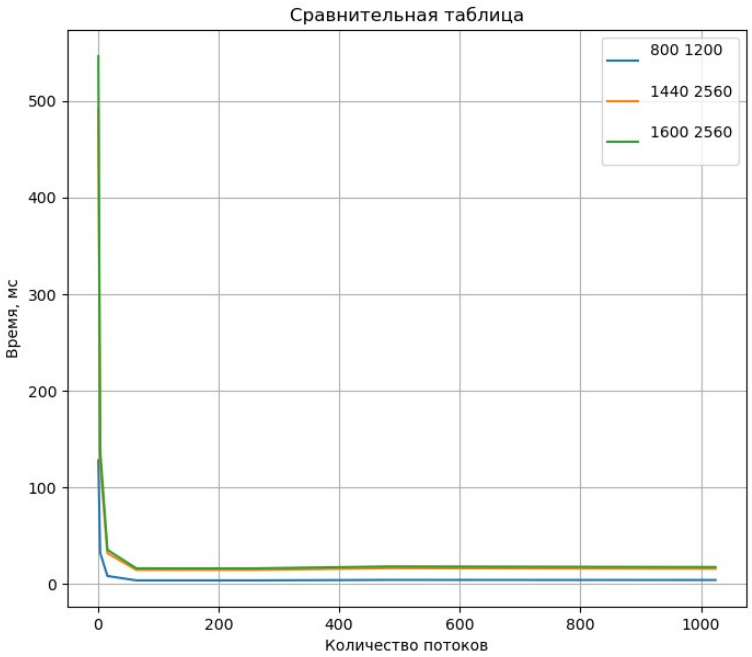

Отсюда видно, что при количество потоков на блок не сильно влияет на производительность, начиная с 32 потоков, составляющих один варп. Впрочем это ожидаемый результат, поскольку каждый пиксель обрабатывается отдельной нитью вне зависимости от количества потоков на одну нить в силу специфики программы. Однако разница значительна, если сравнивать с алгоритмом, написанным на CPU:

```
GPU threads: 1024
time: 4.21114
GPU threads: 1024
time: 15.8575
GPU threads: 1024
time: 17.6306
```

```
CPU
time: 1436.52
CPU
time: 5990.75
CPU
time: 5631.32
```

Выводы

Реализованный мной алгоритм широко применяется при обработке изображений, поскольку позволяет четко выделить контуры, что бывает полезно в задачах машинного обучения. При этом этот алгоритм является достаточно шумным(на изображении можно заметить светлые размывы), поэтому перед его применением рекомендуется применять сглаживающие фильтры.

Алгоритмы свертки хорошо распараллеливаются, что делает эффективным их использование на графических процессорах. Недаром, что современные свёрточные нейронные сети обучаются гораздо быстрее на GPU.

В ходе выполнения работы возникла трудность в том, как расположить данные в текстурной памяти так, чтобы влезть в ограничения, а также было совсем не очевидно, что следует решать задач в оттенках серого, а не в 3-ех каналах RGB изображения.